

机器人 Agent 的上下文学习

经验检索、轨迹示范与主动探测

Research Proposal I · Zimo Wen

September 2026

摘要

机器人进入新环境时，常常能够理解任务，却无法立即知道具体的操作方式和物理条件。增加参数训练可以改善这种能力，但每次任务变化都重新训练，难以适应数据稀缺和交互成本较高的机器人场景。本研究围绕测试时权重固定的 **in-context learning**，提出三个可独立验证的方案：通过条件化检索将历史经验转化为可执行程序；用传感运动示范直接条件化连续动作；通过主动探测获得对当前环境有用的上下文。研究以 **Robot-RSI** 已有计划归档、任务经验和技能执行机制为基础，重点区分任务识别、轨迹复现与真正的交互适应。实验将覆盖少样本新任务、未见物理条件、错误上下文和有限探测预算，检验机器人是否因为读懂了动作与结果之间的关系而改善行为。

1. 研究背景与科学问题

从记住经验到使用经验。 **Robot-RSI** 的计划归档能够向 **Planner** 提供同任务近期计划，并按相关技能版本过滤过期记录；任务 **wiki** 则保留可复用的执行事实。这说明项目已经具备外部记忆基础。下一步值得研究的是：当物体形状、空间关系或接触条件变化时，**agent** 能否判断旧经验中什么仍然适用，以及哪些参数必须通过新观测确定。仅增加历史记录数量，并不保证经验能跨条件迁移。

例如，同样是把杯子放入容器，宽口容器中的成功动作可能无法直接用于狭窄开口。语义任务基本相同，但需要迁移的是避碰原则、接近方向和局部反馈方式，而不是原始坐标。另一个例子是外观相同、摩擦不同的物体：视觉检索可能返回同一示例，机器人必须利用实际推移后的位移和阻力重新判断操作策略。

研究问题。 给定少量允许观测构成的经验 D 、当前任务 g 和近期交互 h_t ，能否在保持参数 θ 不变时获得更有效的策略 $\pi_\theta(a_t | o_t, g, D, h_t)$ ？这里允许上下文随本次交互更新，但不允许正式测试的结果修改后续测试任务的技能、提示或权重。由此获得的适应与跨版本自进化、在线梯度更新分别评价。

现有工作的边界。 **Code as Policies** 已展示由示例引导的机器人程序生成；**ICRT** 已展示传感运动轨迹条件化的测试时模仿学习。本文不把“加入记忆”或“通过示例输出动作”本身作为新颖性主张，而聚焦三个问题：经验适用边界能否被识别；动作—结果的时序对应是否决定迁移；机器人能否主动获得最有信息量的上下文。

可证伪假设。 **H1**：状态条件化的经验选择，在相同 **token** 预算下优于同任务近期计划。**H2**：保留动作—观测对齐的示范，在新物理条件下优于文本摘要及打乱示范。**H3**：主动探测在计入探测成本后仍优于固定探测。若错误示例、时间打乱或配对交换不影响行为，应优先解释为任务识别或脚本复用，而不能据此主张物理 **ICL**。

2. 方案一：基于适用条件检索的程序适应

经验表示。 每段经验存为 $e = (c, p, r, b)$ ： c 是可见场景与交互条件， p 是执行程序或技能序列， r 是观察到的动作结果， b 是适用边界与证据来源。条件包括物体相对位置、可达方向、夹持状态和可用的接触信号；结果包括位移、受阻、滑移和视觉确认。因果解释与直接观测分别标记，避免把一次失败后的猜测固化为事实。

检索与生成。 先按任务与空间关系召回候选经验，再根据当前可见状态及技能接口版本重排。上下文选择同时控制相关性、多样性和长度，避免多个相近成功示例占满预算。**Planner** 根据检索结果形成可执行程序，并说明需要重新测量的变量，例如目标坐标、接近高度和接触方向。程序仅调用声明的观察与动作接口，环境响应通过工具结果进入下一次决策。

核心研究对象是经验的**选择、拒绝与修订**。同一任务可以同时检索正例和反例：成功例提供候选路径，失败例提醒该路径的边界。相比固定 few-shot 提示，我们拟研究能否通过经验有效性预测减少错误迁移；开发阶段可学习重排器，正式测试冻结参数与经验库。经验条目保留生成时的观测和技能版本，但不包含隐藏目标状态或测试成功谓词。

训练与接口。 初始实现使用结构化特征与冻结嵌入检索，便于建立明确基线；进一步在开发任务上，用经验是否改善后续执行的配对数据训练适用性评分。部署后可直接对接 **Robot-RSI** 的计划归档与 **Planner** 上下文构建。实验比较时固定模型、技能库、上下文长度和动作预算，使差异主要来自经验组织方式。

3. 方案二：传感运动示例条件化的动作学习

输入与输出。 将示范表示为时间对齐序列 $D = \{(I_t, s_t, a_t, f_t)\}$ ，其中图像 I_t 、本体状态 s_t 和动作 a_t 为基本输入，力觉 f_t 仅在传感条件确实存在时加入。模型输出当前场景下的短时动作块；近期交互与示范使用不同标识，避免把示范中的未来动作误认为当前已经发生的事件。动作优先采用现有机器人可执行的末端或关节增量。

学习机制。 使用 support-query 训练：同一任务或交互条件的不同布局分别组成示范与目标 episode。上下文编码器提取操作关系、接触阶段和时序结构，动作头根据 query 观测生成控制。训练目标可采用行为克隆或连续动作生成损失，同时随机丢弃示例、改变示例顺序与数量，使模型不能只依赖固定提示模板。测试时保持编码器和动作头权重不变。

区别于轨迹复制。 示范与 query 不共享绝对坐标或初始布局；通过相对几何关系和本体状态归一化降低复制轨迹的捷径。训练集包含视觉相似而响应不同的交互，使模型有机会学习动作后果。验证中分别移除动作、保留图像但打乱动作对齐、用另一物理条件的示范替换原示范，观察策略是否随证据合理变化。

与方案一的关系。 本方案由动作模型直接利用示例，避免所有运动信息都经过文字压缩；代价是需要多任务轨迹训练和严格的时序对齐。它与检索程序方案分别报告结果，再以相同 support 信息进行比较。不能把额外示范模态或更多训练数据带来的增益全部归因于动作模型的 ICL 机制。

4. 方案三：主动探测驱动的上下文适应

为什么主动获取上下文。 被动示例未必描述当前环境。对于质量、摩擦或抽屉阻力，短距离推拉产生的响应可能比额外图像更有价值。本方案让 agent 在继续执行与进行探测之间选择，把“获取经验”也作为决策的一部分。

探测策略。 维护由允许观测形成的候选解释及其不确定性。例如，对受阻抽屉区分方向偏差、夹持滑动与较大静摩擦，但这些只是待检验解释。候选探测的价值可写为 $U(a) = \lambda_I \text{IG}(a) + \lambda_P \text{Progress}(a) - \lambda_C \text{Cost}(a)$ 。信息增益和任务进展从开发数据中估计，不能调用测试环境的隐藏参数。探测结束后，将动作与实际响应加入短期上下文，条件化下一步动作。

实现选择。 先使用有限探测动作集合，如小幅推移、改变拉动方向和短时夹持检查，再比较学习式探测选择。轻量系统辨识加自适应控制作为必要基线，检验显式估计少量参数是否已经足够。探测动作与常规执行共享位移、接触和时间预算；获得信息但耗尽任务预算不算有效提升。




图 1: 三个独立方案的 pipeline。A 通过经验检索条件化程序；B 用轨迹上下文条件化动作策略；C 主动获取响应后更新短期上下文。图由 GPT-image-2 绘制，表达拟议数据流，不表示已完成实验。

数据边界。 图中的 visible feedback 仅包含声明的传感与动作结果。离线示例库在测试前冻结，query 观测只进入当前 episode 的短期状态，评测器标签不进入在线上下文。开发阶段的验证结果可用于筛选经验，但需记录来源；被选中的经验与后续测试任务、物体和 seeds 的关系必须公开。

5. 实验设计：任务、数据划分与对照

两类评测对象。 第一类检验当前短任务能力是否保持，使用 Robot-RSI 的 120 个 LIBERO 短任务冻结面板。第二类专门检验 ICL，在开发、验证和测试任务之间隔离经验来源，并改变任务语义、物体布局或物理条件。标准成绩与新增物理扰动实验单列，避免把同任务历史经验覆盖误写为未见任务泛化。

建议的主实验面板。 从短任务中选择 48 个适合构造经验的任务实例，按底层任务家族分组划为开发 24、验证 8、测试 16 个；共享同一任务配方的语言与布局变体整体分组，若分组后数量无法恰好对应则调整实例数并冻结清单，不能拆开近重复任务满足配额。主测试预设每任务 4 种 query 条件、每条件 5 个 seeds，名义规模为每方法 320 个有效 query episodes。

四种条件分别为同分布新布局、可见几何变化、未见物理条件，以及几何与物理变化的组合。摩擦、质量与阻力仅选择模拟器支持且任务仍可解的范围，开发集确定幅度，验证后冻结。主测试的物理值与训练值不重合；同时报告插值与外推条件，避免仅凭随机重置宣称跨动力学泛化。

support 的来源。 每个 query 预先绑定 0、1、3、5 段示例，来源为独立 seeds 与独立轨迹。为区分学习新任务与适应新条件，分别设“同任务示例、不同物理条件”和“同物理条件示例、不同布局”。所有可接收示范的比较方法共享同一 support；需要文本的基线读取固定规则生成的摘要，摘要的图像或力觉缺失须明确说明。

比较方法	保留的能力	所检验的差异
冻结 Robot-RSI	现有技能与已声明的历史经验	当前系统基线
同任务近期计划	固定数量近期成功计划	状态检索是否优于任务标签
语义检索程序	语义相似经验与代码生成	空间、接触与适用边界的价值
传感运动上下文	示范序列与连续动作策略	原始时序信息的价值
系统辨识控制	同样的探测与传感预算	显式参数估计是否足够
主动探测策略	选择探测并更新上下文	主动获取信息的净收益

冻结与复现。 正式测试固定模型版本、提示、技能、检索库、重排器、探测权重、控制约束和最大调用数。每个 query 重置短期上下文，禁止前一个测试结果写回经验库。保留 exact manifest、视频和完整轨迹；成功 seeds 由 resume 保护，开发后仅重试失败与基础设施中断，不重复调度同版本已成功实例。

成功口径。 标准短任务以 task-level pass@10 报告，按 spatial/object/goal 与 task/object/swap/lan 拆分。ICL 主面板另外报告固定 query 的 episode 成功率，最终标签仅取模拟器或独立 harness。provider、transport、image、resource 与 interrupted 记录单列，不进入有效任务成功分母；同时报告覆盖率，防止只比较容易完成的子集。

6. 预计实验方案：消融与可观察结果

实验 A：上下文数量与信息类型。 在同一 query 面板上改变示例数，绘制成功率随 k 的变化，同时记录 prompt、completion、total tokens 和动作成本。分别比较文本摘要、视觉帧、图像一动作序列与含力觉的完整上下文。预期有效示例带来收益，但过长上下文可能因信息冗余或过期经验降低表现，因此不预设单调增长。若 1 段示例已提供全部收益，应检查它是否只泄露了任务身份。

实验 B：因果配对与错误经验。 固定示例图像与数量，只交换动作一响应配对，或用另一物理条件的示范替换。正确上下文优于这些对照，且行为变化与物理响应一致，才支持模型使用交互关系。交换上下文导致任意退化仅说明敏感性，还需查看控制方向、速度或恢复策略是否按预期改变。增加与任务无关但长度匹配的上下文，排除单纯上下文长度效应。

实验 C：检索的适用边界。 构造语义接近但操作约束不同的任务对，如宽开口与窄开口放置、方向相反的推拉。比较只按语义检索、增加空间条件、增加接触状态，以及带失败边界的经验。主要观察负迁移率：使用经验后原本成功的 query 是否变为失败。人工标注仅用于离线分析示例是否适用，不注入在线 Planner。

实验 D：探测价值。 给主动探测、固定探测和随机探测相同的 0、1、3 次探测额度，并使用相同低层动作集合。将准备动作、探测失败、额外模型调用和恢复全部计入总预算。报告任务成功率、每单位交互时间的成功收益，以及探测后下一动作是否得到有用修正。隐藏参数误差可由评测器离线分析，但不能成为策略测试时读取的输入。

统计设计。 以任务为聚类单位计算配对 bootstrap 置信区间；seeds 反映布局随机性，不将同任务大量轨迹视为独立任务。主终点预先选为未见物理条件下的 query 成功率差值，正确与错配上下文的差值为关键机制终点。使用验证集估计任务间方差和所需样本量；320 个 query 是拟议初始规模，不自动保证检验能力。多个探索性比较与主假设分别标记。

可能观察到的结果	能支持的解释与后续判断
正确上下文明显优于无上下文和错配上下文	支持利用经验；还需通过动作响应分析区分任务识别与物理适应
语义检索与完整时序上下文相当	任务可能主要依赖程序知识；不能主张传感运动 ICL 必要
主动探测提高成功，但总耗时过高	获得信息有效，但部署效率尚不足；需要改进探测选择
系统辨识基线达到相同收益 示例越多反而下降	低维估计已经足够，应限定大模型带来的独立价值 检查过期、矛盾和检索偏差，不能仅扩大上下文窗口

效率面板使用固定 query seeds 配对，报告全部有效 episodes，以及双方均成功子集的中位数；不能只筛选本方法成功的运行。上述结果表是预期分析框架，没有填入模拟或虚构的成绩。训练损失仅作优化诊断，最终结论必须来自冻结策略在匹配与留出任务中的模拟执行。

7. 预期贡献、风险与结论边界

贡献一：明确经验迁移的对象。 通过程序检索、直接轨迹条件化和主动获取上下文的独立比较，本研究希望揭示不同经验表示适合解决哪类机器人问题。任务规则、几何关系、动作节奏与未知物理属性可能需要不同的上下文；论文应报告这些分界，而不仅给出一个平均成功率。

贡献二：建立验证机器人 ICL 的机制证据。 同任务不同条件、视觉相似不同响应以及动作—结果交换组成更有针对性的检验。它们使“模型读到了任务答案”“模型复用了脚本”和“模型利用交互证据适应”能够在一定程度上被区分。任何单个消融都不足以证明模型内部形成了完整物理模型，结论应与实际观测保持一致。

贡献三：量化上下文获取的成本。 机器人获得一条示例往往需要真实交互。将示范制作、主动探测与部署推理分别计量，有助于说明少样本方法何时比微调或显式控制更划算。若示范由人提供，另报人类采集成本；若由机器人获取，则计入测试交互预算。离线训练成本与在线适应成本不混为一项。

主要风险。 第一，经验库可能带有任务或 seed 近重复，需要按任务家族分组并检查来源。第二，力觉和视觉的时间对齐误差可能掩盖 ICL 效果，因此先验证记录和执行时间戳。第三，主动探测可能让物体进入不可恢复状态，需要将这类失败作为任务结果保留。第四，部分任务只需要几何推理，动态适应假设可能不成立，应通过物理敏感任务与普通任务分层分析。

与 Robot-RSI 的连接。 三个方案分别接入经验检索与 Planner、Engineer 的动作策略接口，以及原子技能中的探测和反馈循环。开发期间可通过既有审核机制积累经过验证的程序与数据；冻结测试关闭持久化回写。Reviewer 只分析允许观测轨迹，隐藏成功谓词与物理真值由独立评测器保管。本提案不依赖改动现有远程实验，也没有新增仿真或训练结果。

预期结论。 研究成立的关键不是证明上下文总比训练好，而是识别在什么任务、什么经验和什么成本下，固定模型能从有限交互中获得可重复的行为改进。三个方案允许分别得到肯定或否定结论，任何一个方案都可独立形成完整的实验论文。

参考文献

- [1] Code as Policies: Language Model Programs for Embodied Control. 2022. <https://arxiv.org/abs/2209.07753>
- [2] In-Context Imitation Learning via Next-Token Prediction. 2024. <https://arxiv.org/abs/2408.15980>
- [3] Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. 2023. <https://arxiv.org/abs/2303.04137>
- [4] Octo: An Open-Source Generalist Robot Policy. 2024. <https://arxiv.org/abs/2405.12213>
- [5] Noematrix Team. RoboRSI research preview. 2026. <https://lab.noematrix.ai/blog/2-roborsi-research-preview/>