

机器人 Agent 的上下文学习

经验检索、轨迹示范与主动探测

Research Proposal I · Zimo Wen

September 2026

摘要

机器人进入新环境时，常常能够理解任务，却无法立即知道具体的操作方式和物理条件。增加参数训练可以改善这种能力，但每次任务变化都重新训练，难以适应数据稀缺和交互成本较高的机器人场景。本研究围绕测试时权重固定的 **in-context learning**，提出三个可独立验证的方案：通过条件化检索将历史经验转化为可执行程序；用传感运动示范直接条件化连续动作；通过主动探测获得对当前环境有用的上下文。研究以 **Robot-RSI** 已有计划归档、任务经验和技能执行机制为基础，重点区分任务识别、轨迹复现与真正的交互适应。实验将覆盖少样本新任务、未见物理条件、错误上下文和有限探测预算，检验机器人是否因为读懂了动作与结果之间的关系而改善行为。

1. 研究背景与科学问题

从记住经验到使用经验。 **Robot-RSI** 的计划归档能够向 **Planner** 提供同任务近期计划，并按相关技能版本过滤过期记录；任务 **wiki** 则保留可复用的执行事实。这说明项目已经具备外部记忆基础。下一步值得研究的是：当物体形状、空间关系或接触条件变化时，**agent** 能否判断旧经验中什么仍然适用，以及哪些参数必须通过新观测确定。仅增加历史记录数量，并不保证经验能跨条件迁移。

例如，同样是把杯子放入容器，宽口容器中的成功动作可能无法直接用于狭窄开口。语义任务基本相同，但需要迁移的是避碰原则、接近方向和局部反馈方式，而不是原始坐标。另一个例子是外观相同、摩擦不同的物体：视觉检索可能返回同一示例，机器人必须利用实际推移后的位移和阻力重新判断操作策略。

研究问题。 给定少量允许观测构成的经验 D 、当前任务 g 和近期交互 h_t ，能否在保持参数 θ 不变时获得更有效的策略 $\pi_\theta(a_t | o_t, g, D, h_t)$ ？这里允许上下文随本次交互更新，但不允许正式测试的结果修改后续测试任务的技能、提示或权重。由此获得的适应与跨版本自进化、在线梯度更新分别评价。

现有工作的边界。 **Code as Policies** 已展示由示例引导的机器人程序生成；**ICRT** 已展示传感运动轨迹条件化的测试时模仿学习。本文不把“加入记忆”或“通过示例输出动作”本身作为新颖性主张，而聚焦三个问题：经验适用边界能否被识别；动作—结果的时序对应是否决定迁移；机器人能否主动获得最有信息量的上下文。

可证伪假设。 **H1**：状态条件化的经验选择，在相同 **token** 预算下优于同任务近期计划。**H2**：保留动作—观测对齐的示范，在新物理条件下优于文本摘要及打乱示范。**H3**：主动探测在计入探测成本后仍优于固定探测。若错误示例、时间打乱或配对交换不影响行为，应优先解释为任务识别或脚本复用，而不能据此主张物理 **ICL**。

2. 方案一：基于适用条件检索的程序适应

经验表示。 每段经验存为 $e = (c, p, r, b)$ ： c 是可见场景与交互条件， p 是执行程序或技能序列， r 是观察到的动作结果， b 是适用边界与证据来源。条件包括物体相对位置、可达方向、夹持状态和可用的接触信号；结果包括位移、受阻、滑移和视觉确认。因果解释与直接观测分别标记，避免把一次失败后的猜测固化为事实。

检索与生成。 先按任务与空间关系召回候选经验，再根据当前可见状态及技能接口版本重排。上下文选择同时控制相关性、多样性和长度，避免多个相近成功示例占满预算。**Planner** 根据检索结果形成可执行程序，并说明需要重新测量的变量，例如目标坐标、接近高度和接触方向。程序仅调用声明的观察与动作接口，环境响应通过工具结果进入下一次决策。

核心研究对象是经验的**选择、拒绝与修订**。同一任务可以同时检索正例和反例：成功例提供候选路径，失败例提醒该路径的边界。相比固定 few-shot 提示，我们拟研究能否通过经验有效性预测减少错误迁移；开发阶段可学习重排器，正式测试冻结参数与经验库。经验条目保留生成时的观测和技能版本，但不包含隐藏目标状态或测试成功谓词。

训练与接口。 初始实现使用结构化特征与冻结嵌入检索，便于建立明确基线；进一步在开发任务上，用经验是否改善后续执行的配对数据训练适用性评分。部署后可直接对接 **Robot-RSI** 的计划归档与 **Planner** 上下文构建。实验比较时固定模型、技能库、上下文长度和动作预算，使差异主要来自经验组织方式。

3. 方案二：传感运动示例条件化的动作学习

输入与输出。 将示范表示为时间对齐序列 $D = \{(I_t, s_t, a_t, f_t)\}$ ，其中图像 I_t 、本体状态 s_t 和动作 a_t 为基本输入，力觉 f_t 仅在传感条件确实存在时加入。模型输出当前场景下的短时动作块；近期交互与示范使用不同标识，避免把示范中的未来动作误认为当前已经发生的事件。动作优先采用现有机器人可执行的末端或关节增量。

学习机制。 使用 support-query 训练：同一任务或交互条件的不同布局分别组成示范与目标 episode。上下文编码器提取操作关系、接触阶段和时序结构，动作头根据 query 观测生成控制。训练目标可采用行为克隆或连续动作生成损失，同时随机丢弃示例、改变示例顺序与数量，使模型不能只依赖固定提示模板。测试时保持编码器和动作头权重不变。

区别于轨迹复制。 示范与 query 不共享绝对坐标或初始布局；通过相对几何关系和本体状态归一化降低复制轨迹的捷径。训练集包含视觉相似而响应不同的交互，使模型有机会学习动作后果。验证中分别移除动作、保留图像但打乱动作对齐、用另一物理条件的示范替换原示范，观察策略是否随证据合理变化。

与方案一的关系。 本方案由动作模型直接利用示例，避免所有运动信息都经过文字压缩；代价是需要多任务轨迹训练和严格的时序对齐。它与检索程序方案分别报告结果，再以相同 support 信息进行比较。不能把额外示范模态或更多训练数据带来的增益全部归因于动作模型的 ICL 机制。

4. 方案三：主动探测驱动的上下文适应

为什么主动获取上下文。 被动示例未必描述当前环境。对于质量、摩擦或抽屉阻力，短距离推拉产生的响应可能比额外图像更有价值。本方案让 agent 在继续执行与进行探测之间选择，把“获取经验”也作为决策的一部分。

探测策略。 维护由允许观测形成的候选解释及其不确定性。例如，对受阻抽屉区分方向偏差、夹持滑动与较大静摩擦，但这些只是待检验解释。候选探测的价值可写为 $U(a) = \lambda_I \text{IG}(a) + \lambda_P \text{Progress}(a) - \lambda_C \text{Cost}(a)$ 。信息增益和任务进展从开发数据中估计，不能调用测试环境的隐藏参数。探测结束后，将动作与实际响应加入短期上下文，条件化下一步动作。

实现选择。 先使用有限探测动作集合，如小幅推移、改变拉动方向和短时夹持检查，再比较学习式探测选择。轻量系统辨识加自适应控制作为必要基线，检验显式估计少量参数是否已经足够。探测动作与常规执行共享位移、接触和时间预算；获得信息但耗尽任务预算不算有效提升。




图 1: 三个独立方案的 pipeline。A 通过经验检索条件化程序；B 用轨迹上下文条件化动作策略；C 主动获取响应后更新短期上下文。图由 GPT-image-2 绘制，表达拟议数据流，不表示已完成实验。

数据边界。 图中的 visible feedback 仅包含声明的传感与动作结果。离线示例库在测试前冻结，query 观测只进入当前 episode 的短期状态，评测器标签不进入在线上下文。开发阶段的验证结果可用于筛选经验，但需记录来源；被选中的经验与后续测试任务、物体和 seeds 的关系必须公开。

5. 实验设计：任务、数据划分与对照

两类评测对象。 第一类检验当前短任务能力是否保持，使用 Robot-RSI 的 120 个 LIBERO 短任务冻结面板。第二类专门检验 ICL，在开发、验证和测试任务之间隔离经验来源，并改变任务语义、物体布局或物理条件。标准成绩与新增物理扰动实验单列，避免把同任务历史经验覆盖误写为未见任务泛化。

建议的主实验面板。 从短任务中选择 48 个适合构造经验的任务实例，按底层任务家族分组划为开发 24、验证 8、测试 16 个；共享同一任务配方的语言与布局变体整体分组，若分组后数量无法恰好对应则调整实例数并冻结清单，不能拆开近重复任务满足配额。主测试预设每任务 4 种 query 条件、每条件 5 个 seeds，名义规模为每方法 320 个有效 query episodes。

四种条件分别为同分布新布局、可见几何变化、未见物理条件，以及几何与物理变化的组合。摩擦、质量与阻力仅选择模拟器支持且任务仍可解的范围，开发集确定幅度，验证后冻结。主测试的物理值与训练值不重合；同时报告插值与外推条件，避免仅凭随机重置宣称跨动力学泛化。

support 的来源。 每个 query 预先绑定 0、1、3、5 段示例，来源为独立 seeds 与独立轨迹。为区分学习新任务与适应新条件，分别设“同任务示例、不同物理条件”和“同物理条件示例、不同布局”。所有可接收示范的比较方法共享同一 support；需要文本的基线读取固定规则生成的摘要，摘要的图像或力觉缺失须明确说明。

比较方法	保留的能力	所检验的差异
冻结 Robot-RSI	现有技能与已声明的历史经验	当前系统基线
同任务近期计划	固定数量近期成功计划	状态检索是否优于任务标签
语义检索程序	语义相似经验与代码生成	空间、接触与适用边界的价值
传感运动上下文	示范序列与连续动作策略	原始时序信息的价值
系统辨识控制	同样的探测与传感预算	显式参数估计是否足够
主动探测策略	选择探测并更新上下文	主动获取信息的净收益

冻结与复现。 正式测试固定模型版本、提示、技能、检索库、重排器、探测权重、控制约束和最大调用数。每个 query 重置短期上下文，禁止前一个测试结果写回经验库。保留 exact manifest、视频和完整轨迹；成功 seeds 由 resume 保护，开发后仅重试失败与基础设施中断，不重复调度同版本已成功实例。

成功口径。 标准短任务以 task-level pass@10 报告，按 spatial/object/goal 与 task/object/swap/lan 拆分。ICL 主面板另外报告固定 query 的 episode 成功率，最终标签仅取模拟器或独立 harness。provider、transport、image、resource 与 interrupted 记录单列，不进入有效任务成功分母；同时报告覆盖率，防止只比较容易完成的子集。

6. 预计实验方案：消融与可观察结果

实验 A：上下文数量与信息类型。 在同一 query 面板上改变示例数，绘制成功率随 k 的变化，同时记录 prompt、completion、total tokens 和动作成本。分别比较文本摘要、视觉帧、图像一动作序列与含力觉的完整上下文。预期有效示例带来收益，但过长上下文可能因信息冗余或过期经验降低表现，因此不预设单调增长。若 1 段示例已提供全部收益，应检查它是否只泄露了任务身份。

实验 B：因果配对与错误经验。 固定示例图像与数量，只交换动作一响应配对，或用另一物理条件的示范替换。正确上下文优于这些对照，且行为变化与物理响应一致，才支持模型使用交互关系。交换上下文导致任意退化仅说明敏感性，还需查看控制方向、速度或恢复策略是否按预期改变。增加与任务无关但长度匹配的上下文，排除单纯上下文长度效应。

实验 C：检索的适用边界。 构造语义接近但操作约束不同的任务对，如宽开口与窄开口放置、方向相反的推拉。比较只按语义检索、增加空间条件、增加接触状态，以及带失败边界的经验。主要观察负迁移率：使用经验后原本成功的 query 是否变为失败。人工标注仅用于离线分析示例是否适用，不注入在线 Planner。

实验 D：探测价值。 给主动探测、固定探测和随机探测相同的 0、1、3 次探测额度，并使用相同低层动作集合。将准备动作、探测失败、额外模型调用和恢复全部计入总预算。报告任务成功率、每单位交互时间的成功收益，以及探测后下一动作是否得到有用修正。隐藏参数误差可由评测器离线分析，但不能成为策略测试时读取的输入。

统计设计。 以任务为聚类单位计算配对 bootstrap 置信区间；seeds 反映布局随机性，不将同任务大量轨迹视为独立任务。主终点预先选为未见物理条件下的 query 成功率差值，正确与错配上下文的差值为关键机制终点。使用验证集估计任务间方差和所需样本量；320 个 query 是拟议初始规模，不自动保证检验能力。多个探索性比较与主假设分别标记。

可能观察到的结果	能支持的解释与后续判断
正确上下文明显优于无上下文和错配上下文	支持利用经验；还需通过动作响应分析区分任务识别与物理适应
语义检索与完整时序上下文相当	任务可能主要依赖程序知识；不能主张传感运动 ICL 必要
主动探测提高成功，但总耗时过高	获得信息有效，但部署效率尚不足；需要改进探测选择
系统辨识基线达到相同收益 示例越多反而下降	低维估计已经足够，应限定大模型带来的独立价值 检查过期、矛盾和检索偏差，不能仅扩大上下文窗口

效率面板使用固定 query seeds 配对，报告全部有效 episodes，以及双方均成功子集的中位数；不能只筛选本方法成功的运行。上述结果表是预期分析框架，没有填入模拟或虚构的成绩。训练损失仅作优化诊断，最终结论必须来自冻结策略在匹配与留出任务中的模拟执行。

7. 预期贡献、风险与结论边界

贡献一：明确经验迁移的对象。 通过程序检索、直接轨迹条件化和主动获取上下文的独立比较，本研究希望揭示不同经验表示适合解决哪类机器人问题。任务规则、几何关系、动作节奏与未知物理属性可能需要不同的上下文；论文应报告这些分界，而不仅给出一个平均成功率。

贡献二：建立验证机器人 ICL 的机制证据。 同任务不同条件、视觉相似不同响应以及动作—结果交换组成更有针对性的检验。它们使“模型读到了任务答案”“模型复用了脚本”和“模型利用交互证据适应”能够在一定程度上被区分。任何单个消融都不足以证明模型内部形成了完整物理模型，结论应与实际观测保持一致。

贡献三：量化上下文获取的成本。 机器人获得一条示例往往需要真实交互。将示范制作、主动探测与部署推理分别计量，有助于说明少样本方法何时比微调或显式控制更划算。若示范由人提供，另报人类采集成本；若由机器人获取，则计入测试交互预算。离线训练成本与在线适应成本不混为一项。

主要风险。 第一，经验库可能带有任务或 seed 近重复，需要按任务家族分组并检查来源。第二，力觉和视觉的时间对齐误差可能掩盖 ICL 效果，因此先验证记录和执行时间戳。第三，主动探测可能让物体进入不可恢复状态，需要将这类失败作为任务结果保留。第四，部分任务只需要几何推理，动态适应假设可能不成立，应通过物理敏感任务与普通任务分层分析。

与 Robot-RSI 的连接。 三个方案分别接入经验检索与 Planner、Engineer 的动作策略接口，以及原子技能中的探测和反馈循环。开发期间可通过既有审核机制积累经过验证的程序与数据；冻结测试关闭持久化回写。Reviewer 只分析允许观测轨迹，隐藏成功谓词与物理真值由独立评测器保管。本提案不依赖改动现有远程实验，也没有新增仿真或训练结果。

预期结论。 研究成立的关键不是证明上下文总比训练好，而是识别在什么任务、什么经验和什么成本下，固定模型能从有限交互中获得可重复的行为改进。三个方案允许分别得到肯定或否定结论，任何一个方案都可独立形成完整的实验论文。

参考文献

- [1] Code as Policies: Language Model Programs for Embodied Control. 2022. <https://arxiv.org/abs/2209.07753>
- [2] In-Context Imitation Learning via Next-Token Prediction. 2024. <https://arxiv.org/abs/2408.15980>
- [3] Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. 2023. <https://arxiv.org/abs/2303.04137>
- [4] Octo: An Open-Source Generalist Robot Policy. 2024. <https://arxiv.org/abs/2405.12213>
- [5] Noematrix Team. RoboRSI research preview. 2026. <https://lab.noematrix.ai/blog/2-roborsi-research-preview/>

机器人 Agent 的底层控制

反馈程序、接触参数与关节残差

Research Proposal II · Zimo Wen

September 2026

摘要

机器人 agent 可以正确描述目标并调用动作技能，却仍在接触、受阻和精细操作中失败。原因可能是当前动作接口无法表达所需的反馈关系：位置目标描述“到哪里”，但不能充分表达“用多大力”“遇到阻力如何让步”以及“如何补偿局部动力学误差”。本研究以 Robot-RSI 已有程序执行、末端运动与 Flexiv 接触接口为基础，比较三个独立方案：生成可执行的反馈控制程序；直接输出位置一力和阻抗参数；通过轻量策略输出关节空间控制残差。实验在观测、数据和预算匹配的前提下，检验更低层的输出是否改善接触任务的成功率、力学质量和泛化，并明确不同控制抽象的能力边界。

1. 研究动机与当前系统边界

当前输出已经超出语义。 Robot-RSI 的 Planner 与 Engineer 可以组织可执行技能，LIBERO 的末端增量技能通过 servo 和运动求解转换为关节增量及夹爪动作。因此，研究起点不是让系统第一次产生数值动作，而是选择哪些控制变量应当交给模型，以及模型应以什么频率、依据哪些反馈更新它们。

Flexiv adapter 提供关节状态、关节力矩和外力读取，夹爪接口接受力参数；接触下放 handler 按外力变化阈值停止。这些能力为研究提供入口，但不能证明 agent 已经学习持续接触控制。所读 CartesianMotionForce 包装主要传入位姿与速度，并留有硬件接口确认事项。接触检测、夹爪闭合力与六维末端接触力分别对应不同物理对象，实验需要明确区分。

问题实例。 将物体放到未知高度的表面，机器人需要从接近转入接触，并避免过大冲击；沿表面推动物体，机器人需要维持法向接触，同时沿切向移动；拉动受阻抽屉，需要区分摩擦、方向偏差与夹持滑动。这些任务可能通过反馈程序、适当的阻抗参数或更低层残差解决，不能预设越低层一定越好。

研究问题。 在相同可见观测和交互预算下，怎样的动作接口能够最好地平衡任务表达力、接触适应、数据效率与控制可靠性？程序层能够表达条件和恢复逻辑；任务空间参数能够表达期望力与柔顺性；关节空间残差能够补偿局部动力学。三个方案分别建立基线，比较适用条件，而非要求它们都进入同一系统。

相关工作与差异。 Code as Policies 已展示模型生成反馈程序，包括阻抗控制实例；Diffusion Policy 与 π_0 提供连续动作生成基础。本文拟研究的额外问题是：任务语义和实时接触证据能否自动转化为合适的控制结构或参数，以及这种选择能否迁移到未见接触条件。仅将接口字段从位置扩展为力，或使用更大动作模型，不足以构成研究贡献。

可证伪假设。 H1: 生成局部反馈逻辑比开环程序更能恢复接触偏差。H2: 可调位置一力与阻抗参数在相同传感条件下优于固定位置与接触停止。H3: 受限关节残差只在任务空间控制难以补偿的条件下带来额外收益。最终需以模拟或真机执行结果验证，参数约束与训练损失本身都不能证明控制稳定或任务改善。

2. 方案一：生成局部闭环控制程序

表示与运行机制。 模型输出带有分支、循环和退出条件的控制程序，读取视觉偏差、本体状态、夹持状态和可用力觉。程序可以表达“沿可见目标方向接近；检测接触后降低速度；若进展停滞且侧向力上升，则改变局部搜索方向”。大模型负责生成可检查的控制逻辑，本地运行时在既定周期内执行反馈；避免每次微调都发起一次远程语言推理。

可生成的范围。 提供类型化原语，如读取误差、设置短时位姿目标、读取接触量、改变控制模式和结束当前动作。程序声明作用坐标系、动作边界、最长执行时间、更新周期及终止条件。编译或校验阶段检查输入输出、无限循环和接口一致性；运行阶段通过控制所有者串行应用动作。语法正确不等于物理正确，程序必须进入真实模拟器反馈闭环才能评价。

学习与适应。 使用开发任务轨迹形成“场景条件—程序—执行响应”的训练或检索样本。模型先生成候选程序，独立验证后在开发环境中修订。重点比较反馈结构是否可以跨物体和布局复用：固定控制逻辑只更新感知参数，与重新生成整个程序分别评价。正式测试冻结模型、提示和程序库，允许在当前 episode 中生成局部程序，但不把测试结果沉淀到后续任务。

关键贡献与对照。 设置固定技能、开环生成程序、手工闭环程序和模型生成闭环程序四组。开环与闭环版本尽量共享接近路径和原语，差异集中在观测条件与修正逻辑。若模型只重现手工模板，贡献应表述为任务条件化选择与泛化，而不能宣称发现了新的控制算法。主要观察局部偏差恢复、成功率和减少模型调用的能力。

3. 方案二：生成位置一力与阻抗参数

动作空间。 策略生成 $a_t = (\Delta x, \Delta R, f^*, K, D, m)$ ，其中位姿增量控制运动， f^* 表示指定轴的期望接触力， K, D 表示刚度与阻尼， m 表示接触模式。采用接触坐标系明确法向和切向，以选择矩阵分离受力控制轴与位置控制轴，避免在同一自由度上施加不相容目标。

反馈控制。 本地控制器结合位置误差、速度和力误差实现参考量。例如，法向导纳环可根据 $f^* - f_t$ 调整微小位移，切向保持轨迹跟踪。策略按照较低频率更新参数，控制器在设备支持的较高频率闭环执行。每次参数变化经过幅度与变化率限制；接触建立、维持和脱离分别处理，防止模式切换引入突变。正定刚度是必要工程约束之一，不构成整体稳定性证明。

模型学习。 可以先从手工验证的控制模板收集成功与失败数据，学习任务和观测条件到参数的映射；再与基于连续动作生成的控制头比较。训练监督包括动作参数与执行结果，但最终选模依赖验证任务的物理表现。力传感的偏置、坐标转换和滤波延迟作为记录的一部分，不将未补偿的重力或惯性变化简单解释为接触变化。

适用问题。 本方案重点研究接触下放、保持接触推移与受阻抽屉交互。它可以在低维参数空间中利用物理结构，预期比直接学习所有关节动作更节省数据，但也可能受接触方向估计和模板适用范围限制。比较固定参数、逐任务人工调参和观测条件化参数，才能识别学习策略的独立贡献。

4. 方案三：关节空间的有界残差控制

研究对象。 保留已验证的基线控制器，由轻量动作网络根据本体状态、力觉和任务条件产生局部关节力矩修正：

$$\tau_t = \tau_{\text{base}}(s_t) + \text{clip}(\delta\tau_\theta(s_t, g, h_t), -b, b).$$

残差幅度 b 、变化率和接触功率限制在验证阶段固定。轻量网络运行在本地控制路径，语言模型负责较慢的任务条件；本方案不要求语言模型以 **token** 生成高频力矩。

训练与接口。 在实际支持力矩命令的仿真中，先通过基线控制器建立可执行行为，再用示范或强化学习学习剩余误差。随机化负载、摩擦、执行延迟和传感偏置，避免残差只补偿固定模拟器误差。策略仅读取可部署观测；隐藏动力学参数可以由评测器用于划分条件和离线分析，不能进入 actor。真机阶段需重新验证控制频率、通信延迟和基线控制器一致性。




图 1: 三个控制方案分别输出反馈程序、任务空间控制参数和关节残差。图由 GPT-image-2 绘制。B 行将机器人执行包含在 local controller 路径中，new observation 实际由机器人传感器返回；三行是独立比较方法。

关键比较。 依次比较无残差、末端位姿残差、阻抗参数调整和关节力矩残差，并匹配训练数据、参数规模与观测。若更低层输出仅在特殊误差下有效，应报告条件边界；若观测不足导致不稳定，则不能用更强限制掩盖失败后只展示成功轨迹。残差裁剪是执行约束，不是可靠性证明。

5. 实验设计：任务与控制变量

标准能力与接触能力分开。 标准 LIBERO 120 个短任务用于观察新执行模块是否损害基础任务表现，采用冻结方法的 task-level pass@10，并按 subset 与 suite 拆分。研究接触参数与关节力矩的主实验另建兼容 LIBERO 操作任务的控制扩展，明确改变的控制器、传感器和动作空间。不能将扩展环境的收益直接计入标准基准成绩。

建议主面板。 选择接触下放、沿表面推移、抽屉交互三类任务，每类 4 个物体或几何配置，共 12 个冻结任务实例。开发与验证使用不同物体、布局及动力学条件，测试面板不用于调参。每任务设置 3 级预先冻结的物理变化与 5 个独立初始 seeds，形成每方法 180 个主测试 episodes。物理变化可以是摩擦、阻力或表面高度，但每个任务只选择有明确物理意义的变量。

单因素与组合条件。 先分别改变摩擦、负载、表面位置和动作延迟，检验每个方案的机制；再设未见因素组合，例如高度偏差与摩擦同时变化。不能把“阻力更大”与“任务不可解”混为一类，开发阶段需以已知有效控制器验证扰动范围。对于夹持滑移和接触分离，使用任务适配的判定窗口，并报告误检。

对照组	动作表达与反馈	需要保持匹配的条件
固定位置控制	位姿或关节增量	同样的视觉、本体与可用力觉
接触停止	位置运动加外力阈值	相同阈值标定与执行限制
人工闭环控制	固定反馈程序及调参控制器	相同控制原语和观测延迟
生成反馈程序	条件、循环与局部恢复	相同原语和语言模型预算
学习接触参数	位姿、目标力与阻抗	相同训练数据和允许接触范围
关节残差	基线加有界力矩修正	相同观测和近似模型容量

公平性。 动作接口与反馈模态是两个独立因素。主要比较使所有策略看到相同的力觉，再增加无力觉消融，区分“有更多信息”和“能表达不同控制”带来的收益。控制更新频率、动作时域和底层限幅分别记录。模型结构无法完全相同时，报告参数量、训练数据量、训练计算和部署延迟，并给出同规模或同延迟的辅助对照。

真机验证设定。 若 Flexiv 持续力控制与日志链路已经确认，可选择三类匹配任务，每类 3 个物理配置、每配置 10 次随机初始试验，作为每方法 90 次的初始验证规模。仿真参数选择与真机初始标定在正式试验前冻结；训练物体和测试物体分离。力矩残差仅在真实接口确实支持且完成控制验证时纳入，否则单列为仿真结论，不把两者混为 sim-to-real 成功。

6. 预计实验方案：物理指标与机制检验

实验 A：动作抽象比较。 在固定可见观测下，依次比较技能或位置接口、生成反馈程序、接触参数和关节残差。最终成功率为主终点，辅以接触质量，避免“更快完成但冲击更大”的方法被单一成功指标掩盖。任务未完成时也保留完整力曲线与动作轨迹，不只统计成功 episodes 的峰值力。

物理质量指标。 接触建立阶段报告峰值力、接触冲量、过冲及稳定时间；维持接触阶段报告力跟踪均方根误差、接触丢失比例和滑移；运动阶段报告位置误差、完成时间与异常振荡。力误差仅在确实存在目标力的接触区间计算，不将自由空间时段混入降低平均误差。不同任务分别报告物理单位，再根据预注册规则形成跨任务比较。

实验 B：接触模式与柔顺性的贡献。 固定位置一力策略的结构，依次去掉可调刚度、可调阻尼、接触模式切换和短期反馈。比较只预测力、只预测柔顺性和联合预测，检查是否存在参数冗余。参数曲线必须与接触阶段对齐分析：若模型始终输出同一组值，应将其视为自动选定固定参数，而不是在线适应。

实验 C：生成程序的反馈是否被使用。 保留程序结构和总动作预算，延迟或冻结某一反馈通道，或在开发确认有效的局部扰动下移除对应恢复分支。比较程序能否在接触异常发生后改变行为。限制重复生成整个程序的次数，使性能不依赖无限次重新规划。逐步检查错误来自感知、条件判断、动作原语还是控制接口，避免笼统归因为大模型推理能力。

实验 D：残差真正补偿了什么。 改变负载和摩擦，分析残差与基线误差之间的关系；与等幅度随机残差、末端残差及更精细的基线调参比较。若残差主要抵消固定重力补偿误差，说明标定和建模可能比学习更直接。再加入执行延迟与传感偏置，检验残差是否放大高频噪声。所有保护触发与不稳定轨迹都保留并单列。

预计结果模式	可以形成的研究判断
反馈程序提升恢复，接触参数进一步降低峰值力	两种输出解决不同层面的误差，应分别解释任务与物理收益
接触参数达到残差同等成功且数据更少	低维物理结构足够，不支持普遍降低到力矩层的必要性
残差只在未见负载下带来收益	支持特定动力学补偿价值，需要报告正常条件下是否退化
成功率提高但振荡、保护触发增加	不能宣称整体控制改善，应同时展示可靠性代价
力觉输入有效、不同动作接口差异很小	感知可能是主要瓶颈，动作表示贡献需要收缩

统计与成本。 以任务实例为聚类单位，报告匹配 seeds 的成功率差值和 bootstrap 置信区间；真实机器人按试验块随机化方法顺序，减小温漂与设备状态影响。记录模型调用、tokens、感知／动作／恢复耗时、训练量和保护触发率。预先选定成功率与一项任务相关接触质量主指标，其他指标作为解释性结果，避免事后挑选最有利曲线。

7. 实验可行性、风险与预期贡献

控制接口是实验前提。 LIBERO 所读路径使用关节增量控制，接触参数与力矩实验需要真正实现并验证对应控制器。最小接口验证包括自由空间跟踪、已知表面接触、坐标变换、传感偏置、模式切换和命令延迟。对真机同样应通过 SDK 文档及功能实验确认接口语义。此处的验证用于保证研究变量存在，不将控制器能运行当作学习方法成功。

稳定性与模型边界。 本研究不预先声称生成程序、正定阻抗或有界残差能保证任意接触下稳定。可在适用条件明确的局部线性或被动性模型下分析，并通过仿真和真机测量检查超出假设的行为。若复杂控制输出频繁触及限制，需报告饱和比例和实际执行动作，使读者能判断究竟是模型还是控制器保护在完成任务。

从仿真到真实。 摩擦、接触刚度、传感器滤波和末端工具参数都可能存在模拟偏差。开发阶段可进行域随机化和设备标定，但应分别记录训练随机化范围、验证选值与真实测试条件。仅在一个物体上成功不能证明接触泛化；至少需要匹配条件和未见条件分别验证，并报告无法迁移的模式。

结果与失败口径。 最终任务成功由模拟器或独立 harness 判定；基础设施和中断单列，代码异常与保护触发也分别报告。若某种控制方式频繁无法执行，不能只保留剩余有效 episodes 的高成功率而宣称更可靠。主表同时给出计划实例数、有效 verdict、任务成功/失败、infra 和实现错误覆盖。保留视频、力曲线、轨迹、诊断与精确 manifests。

预期贡献。 第一，给出面向机器人 agent 的动作抽象比较，确定反馈程序、接触参数和关节残差各自解决的误差类型。第二，提出在任务语义与实际接触观测之间建立可执行映射的方法，并以未见物体和动力学条件验证。第三，将接触质量、部署延迟和数据成本纳入评测，避免把“能输出更底层动作”直接等同于更强的机器人能力。

独立性。 三个方案可以共享任务与日志协议，但其方法、训练条件和实验结论分别报告。已有 Robot-RSI 的技能库和角色链提供研究基础；本提案不依赖其他两个 proposal 的上下文学习或即时响应模块。文中的样本量是待验证的实验设计，不是已完成结果。

参考文献

- [1] Code as Policies: Language Model Programs for Embodied Control. 2022. <https://arxiv.org/abs/2209.07753>
- [2] Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. 2023. <https://arxiv.org/abs/2303.04137>
- [3] π_0 : A Vision-Language-Action Flow Model for General Robot Control. 2024. <https://arxiv.org/abs/2410.24164>
- [4] Octo: An Open-Source Generalist Robot Policy. 2024. <https://arxiv.org/abs/2405.12213>
- [5] Noematrix Team. RoboRSI research preview. 2026. <https://lab.noematrix.ai/blog/2-roborsi-research-preview/>

动态环境中的机器人 Agent

事件触发、异步执行与预测控制

Research Proposal III · Zimo Wen

September 2026

摘要

机器人 agent 的推理往往基于已经过去的观测，而动作会在推理和通信结束后继续执行。即使任务规划正确，目标移动、物体滑落、接触受阻或指令变化也可能使当前动作失效。本研究将即时响应定义为环境事件能够多快地转化为实际有效的控制修正，提出三个可独立研究的方案：事件触发的可抢占技能执行；延迟感知的异步动作分块；结合状态预测与不确定性的前瞻控制。研究基于 Robot-RSI 的技能运行机制与机器人接口，构建受控动态扰动面板，区分感知、检测、推理、调度和执行延迟，并联合评价响应速度、恢复质量、最终成功率与推理成本。

1. 问题定义与研究动机

即时响应不等于更快生成答案。 假设机器人正在伸手抓取一个杯子，杯子在运动中被移动。模型更快输出下一条指令，并不意味着正在执行的旧动作已经停止；若新指令仍依据移动前的图像，也可能更快地执行错误动作。类似地，抓取滑落要求处理夹持状态，而新的用户指令可能要求改变目标。不同事件需要不同的响应层级和验证标准。

当前系统的切入点。 Robot-RSI 的部分运动技能已包含局部反馈，Flexiv 的接触下放也能在内部检测外力并停止。这些局部能力需要与任务级响应区别对待。所读 sidecar 将运动、状态和停止请求放在同一请求锁内，外部状态查询或停止可能等待当前运动 handler 返回。该判断仅针对软件请求路径，不涉及独立硬件急停能力。研究需要让环境变化能够及时进入执行管理，而不只是缩短语言推理时间。

统一的测量对象。 定义事件真实发生时刻为 t_e ，纠正动作实际开始生效的时刻为 t_a ，则响应延迟为 $L = t_a - t_e$ 。事件发生时刻由评测器记录，不能提前提供给策略。除了响应延迟，还应测量恢复到有效任务进展的时间和最终成功率。立即停止可以缩短某类动作响应，却不必然完成任务；两者需独立统计。

三种研究选择。 事件触发方案研究何时中断以及如何保证旧动作失效；异步分块方案研究在推理尚未完成时如何连续执行并接纳新观测；预测控制方案研究如何依据动作真正执行时的未来状态决策。它们分别对应离散技能、连续动作生成和前瞻规划，不要求共同部署才能获得结论。

假设与相关工作。 H1: 可抢占执行在匹配感知频率下改善扰动恢复。H2: 延迟与状态变化条件化的动作前缀在相同推理预算下优于固定分块。H3: 校准的不确定性与短时预测能改善延迟下的操作，但预测错误可能使表现退化。Real-Time Chunking 已研究异步连续动作执行；本研究重点检验状态变化导致的动作失效、实际控制响应及其与最终成功的关系，不将异步推理本身作为新颖性主张。

2. 方案一：事件触发的可抢占技能执行

事件与动作有效性。 每个技能声明必要前提，例如目标仍位于允许区域、夹持状态未改变、当前路径的可见空间条件仍成立。感知模块持续输出带时间戳的观测，事件检测器根据变化幅度、置信度和任务阶段决定是否触发。局部小偏差可以交给原有控制器，明显目标变化或接触失效才请求恢复或重规划，避免每一帧视觉噪声都引起中断。

抢占协议。 动作包带有技能编号、计划版本、观测时间戳、有效期限和取消标识。发生事件后，运行时撤销尚未执行的命令，由唯一控制所有者完成停止或切换，并返回确认。新的 **agent** 输出若基于旧版本或已过期观测，必须重新校验才能执行。取消等待任务不代表机器人停止，执行记录需同时包含取消请求、控制器接受及观测到的实际响应。

恢复策略。 先执行本地可验证的恢复，如减速、保持、撤回短距离或重新观察；仅在目标或程序假设失效时调用慢速 **Planner**。检测器采用去抖、滞回和冷却时间，既降低误触发，也防止错误冷却让关键事件被忽略。比较固定阈值与开发阶段学习的事件评分，测试时固定参数。人工指定事件发生时刻只能用于离线对照，不输入在线调度器。

核心验证。 与技能结束后检查、固定周期检查和同感知频率的无抢占方法比较。记录误触发、漏检、被撤销命令和陈旧动作执行次数，分析收益来自事件判断还是执行层真正支持中断。独立高优先级取消通过控制线程或命令队列实现，不能简单让多个线程同时调用机器人模式切换。

3. 方案二：延迟感知的异步动作分块

基本矛盾。 连续动作模型一次生成 H 步动作。较长动作块能够减少推理停顿，却会延长旧观测影响控制的时间；较短动作块更易更新，但若推理时间超过动作执行时域，就会出现空档或抖动。本方案让下一动作块推理与当前执行重叠，并根据延迟和环境变化调整承诺执行的前缀。

动作对齐。 设控制周期为 Δt ，推理与传输延迟估计为 $\hat{L}$ ，则必须承诺的前缀至少需要覆盖相应不可撤销执行窗口，初始估计可取 $p \approx \lceil \hat{L} / \Delta t \rceil$ ，再加入已执行状态与设备缓冲约束。新动作块从实际执行位置衔接，不能假设它仍从请求发出时的状态开始。延迟估计使用近期实测分布，并对突发长尾做超时处理。

状态变化条件化。 固定前缀长度可能在静态任务中过于保守，在动态任务中又反应过慢。根据目标速度、接触变化和预测不确定性调节动作时域；当旧前缀的有效性条件不再成立时，通过设备允许的取消边界更新动作。使用速度或加速度连续性约束衔接，避免为了更快响应产生不必要的剧烈变化。

研究增量。 **Real-Time Chunking** 作为主要基线；比较固定异步分块、仅按延迟调整、仅按状态变化调整和联合调整。所有方法共享动作模型与权重，使实验聚焦执行算法。若状态变化管理不能改善最终任务或尾延迟，则应将结果限定为特定延迟条件下的执行优化。

4. 方案三：预测式状态更新与前瞻控制

预测动作生效时的环境。 策略不只使用最近一帧目标位置，而是估计动作真正执行时的状态。输入包括观测历史、本体状态、候选动作以及测得的延迟；模型预测短时状态和不确定性。控制器通过滚动优化选择动作，只执行前缀，再用新观测校正。先比较恒速外推或简化动力学模型，之后再引入学习式动作条件模型，避免默认复杂模型更好。

优化与不确定性。 选择动作以平衡任务进展、控制变化和预测风险，可写为 $\min_{a_{t:t+H}} \mathbb{E}[C_{\text{task}}] + \lambda_U C_{\text{uncertainty}} + \lambda_A C_{\text{action}}$ 。不确定性较高时缩短时域、补充观测或选择更保守的局部动作。预测模型仅用允许观测学习；模拟器未来真值可作为离线误差评测，不提供给规划器。




图 1: 三个即时响应方案的 pipeline: 事件触发、异步分块和前瞻控制。图由 GPT-image-2 绘制，三条路径是独立方案。评价终点是实际动作响应及最终任务结果，而不是模型输出完成时刻。

关键机制实验。 设置目标恒速移动、突然变向、短时遮挡和接触条件变化。若预测在平滑运动有效、在突变时失效，应通过不确定性校准和观测校正分析边界。需要同时报告预测误差与闭环收益：图像或状态预测更准确不保证控制更好，过度保守也可能降低完成率。真机测试若存在时钟不同步，必须先建立跨设备时间对齐，否则毫秒级结论不可信。

5. 实验设计：动态任务与延迟干预

动态扰动面板。 在 LIBERO 短任务上构建任务适配的四类事件：目标移动、抓取或接触状态变化、可见路径条件变化，以及执行中的指令修订。每类事件都应发生在方法尚未完成相关动作时，并保持任务可解；例如已抓住物体后不再用任意瞬移目标模拟自然运动。事件由评测器统一注入，策略只通过允许传感或指令通道发现变化。

建议规模。 选择 24 个任务—事件配对，使各事件类型覆盖多个操作任务。每个配对设 3 级扰动强度、4 个延迟档和 5 个 seeds，主面板为每方法 1,440 个 episodes。24 个配对不等于 24 个相互独立的任务，统计时仍按底层任务聚类。先用独立开发和验证面板检查可解性、事件幅度与时序，再冻结测试清单；名义规模根据开发方差调整，不从测试结果反向决定样本数。

延迟设置。 主实验可预设额外推理延迟 0、100、300、600 ms 四档，并报告每次运行实际总延迟。额外延迟分别加在感知传输、模型推理或动作提交路径，不能将三类干预混为同一变量。增加独立的随机长尾延迟实验，检验均值相同而 p95 不同的条件。若基线推理已远慢于这些档位，按验证测得的控制与任务时间尺度调整并冻结档位。

比较方法	更新与执行方式	主要检验对象
同步技能基线	技能结束后观察和决策	当前任务级闭环
高频定时检查	相同传感频率，周期式更新	感知密度本身的作用
事件抢占	事件有效性判断与控制确认	中断和恢复机制
同步短动作块	缩短动作时域，推理后执行	频繁更新的资源代价
RTC 异步基线	固定模型的异步分块	连续执行与延迟处理
状态条件异步	动态时域及前缀失效管理	状态变化与延迟联合处理
预测控制	延迟补偿、滚动优化与校正	前瞻状态的独立价值

控制混杂因素。 事件方案共享感知模型和频率，异步方案共享动作模型及训练权重，预测方案比较同计算预算和同动作限制。全部方法记录实际采样频率、队列长度、推理调用及累计计算时间。仅让一个方法调用更多 GPU 或更高频率感知不能证明调度更好，因此另设同计算预算的 Pareto 比较。

基准边界与复现。 动态扩展与标准 120 个短任务分开报告；标准任务仍用 task-level pass@10，并按 spatial/object/goal 和 task/object/swap/lan 拆分。动态主表使用固定扰动实例的 episode 成功率与延迟分布。manifest 固定任务、seed、事件轨迹、触发规则、延迟样本和方法版本，保留所有执行证据及成功 seed resume 保护。跨方法运行是独立对照；同一方法不重复运行已经成功的 task/seed 配置。

6. 预计实验方案：从事件到恢复的测量

测量分解。 记录事件真实发生 t_e 、首个包含事件的传感采样 t_s 、检测 t_d 、决策或局部修正就绪 t_p 、控制器接受 t_c 及实际动作变化 t_a 。各环节延迟分别为 $t_s - t_e$ 、 $t_d - t_s$ 、 $t_p - t_d$ 、 $t_c - t_p$ 和 $t_a - t_c$ 。若方法持续更新而没有显式事件检测时刻，则报告可定义的公共环节，不编造对应时间点。

什么算有效响应。 事先按事件类型定义：移动目标对应动作朝新目标修正；滑移对应保持、再夹持或恢复动作；阻挡对应减速、停止或改变路径；指令修订对应停止执行与新目标矛盾的动作。所有判定规则在验证阶段冻结，由评测器离线计算。物理可观测变化可辅助识别响应，不使用 Planner 的“已响应”文本作为证据。

实验 A：事件触发机制。 匹配传感频率，比较有无抢占、有无有效期限、固定阈值与学习式事件评分。测量误触发率、事件漏检率、停止确认失败和陈旧动作执行。增大噪声或遮挡，观察阈值与滞回是否只在特定条件有效。事件检测准确但控制仍未变化，说明瓶颈在执行层；能快速停机但无法恢复，则需要分别报告响应和任务失败。

实验 B：异步执行与尾延迟。 改变模型延迟均值、方差和突然尖峰，比较动作块长度、冻结前缀、状态变化阈值与衔接方式。主指标为扰动后成功率、响应 p95，以及动作连续性；p50、p99 和控制空档作为辅助。p99 需要足够有效事件，不在事件数很小时作强结论。报告动作速度和加速度变化，避免用激烈动作换取表面上的快速响应。

实验 C：预测是否改善控制。 分别移除延迟补偿、不确定性项和新观测校正，比较恒速模型与学习式模型。目标恒速和突然转向分别统计，观察预测误差与任务失败之间的关系。使用仅供离线分析的未来状态上界对照时，须与可部署方法分表，绝不向正式 agent 提供未来真值。

实验 D：响应—成本取舍。 在多个固定调用或推理计算预算下，绘制成功率、响应 p95 与 tokens / wall time 的比较。事件触发在静态场景应能减少不必要的模型调用；异步推理可能提高利用率但增加累计计算；预测模型可能更准确却因耗时抵消收益。比较端到端成本，不能仅报告大模型等待时间下降。

可能的实验结果	合理解释
响应更快且扰动后成功率提高	支持有效响应改善；继续检查感知和计算是否匹配
停止更快但恢复更慢或任务失败增多	只能主张停止链路改进，不能主张更强动态操作能力
异步方法平滑但突变时仍执行旧动作	连续性收益存在，前缀有效性管理仍是瓶颈
预测在平滑运动有效、在变向时退化	需要限定运动条件并分析校正和不确定性
高频定时检查达到同等效果	事件方法的独立收益可能主要体现在计算节省

7. 统计、风险与预期研究贡献

统计协议。 以任务为聚类单位进行配对 bootstrap，保持事件轨迹和延迟样本跨方法一致。预注册主要结果为扰动后的最终成功率差值与响应 p95；补充检测、恢复和计算指标。未能响应的 episode 不能从延迟统计中静默删除；同时报告未响应比例、超时阈值及有效响应条件下的分位数，必要时用生存分析处理删失，防止只统计能响应的少数案例。

执行真实性。 软件日志可能显示命令已提交，而机器人仍执行缓冲中的旧动作。需要本体状态、控制器确认与时间戳联合验证；多设备采用统一时钟或离线校正，并量化同步误差。模拟器物理时间与真实 wall time 分开记录，在加速仿真中尤其不能将二者直接混用。图像帧生成时间、接收时间和模型消费时间也应分别保存。

主要风险。 第一，事件检测可能过于任务特定，在新任务上产生误触发；需要按任务家族留出测试。第二，频繁中断可能破坏原本稳定的局部控制，需要明确取消边界与平滑衔接。第三，预测模型在突变下会失准，必须评价不确定性校准和退化行为。第四，不同方案对模型和执行接口要求不同，应给出各自匹配基线，不能强行使用一个无法公平比较的总排名。

成功和错误记录。 最终成功只由模拟器或独立 harness 判定，provider、transport、image、resource 和 interrupted 记录从任务成功分母中排除并单列。实现错误、无响应、控制保护触发及未完成覆盖分别公布。效率按 episode 记录 prompt / completion / total tokens、VLM 调用与未计量调用、wall time 及感知/动作/恢复耗时。视频、轨迹、日志与失败证据全部保留，训练模型必须在匹配与留出任务中进行模拟评测。

预期贡献。 本研究希望形成三个独立结果：一套保证技能有效性并支持真实抢占的事件执行机制；一种在延迟和状态变化下调整动作承诺范围的连续执行方法；一套检验预测是否改善实际响应的闭环控制方案。共同的评测贡献是将事件发生、控制生效、恢复和完成任务清晰分开，让“实时”成为可以比较的测量结果。

与其他方向的关系。 本文可以使用固定技能库或冻结动作策略开展，不依赖先完成上下文学习或学习力控。三个方案也可独立验证。文中的任务规模、扰动幅度和延迟档位均是拟议实验设置，需通过开发与验证面板冻结；当前没有新方法的实测成绩。

参考文献

- [1] Real-Time Execution of Action Chunking Flow Policies. 2025. <https://arxiv.org/abs/2506.07339>
- [2] Diffusion Policy: Visuomotor Policy Learning via Action Diffusion. 2023. <https://arxiv.org/abs/2303.04137>
- [3] π_0 : A Vision-Language-Action Flow Model for General Robot Control. 2024. <https://arxiv.org/abs/2410.24164>
- [4] Code as Policies: Language Model Programs for Embodied Control. 2022. <https://arxiv.org/abs/2209.07753>
- [5] Noematrix Team. RoboRSI research preview. 2026. <https://lab.noematrix.ai/blog/2-roborsi-research-preview/>